

گزارش پروژه خوشه‌بندی و طبقه‌بندی داده‌های فروش آپارتمان

در این پروژه هدف اصلی تحلیل داده‌های مربوط به فروش آپارتمان و بررسی ساختار پنهان داده‌ها با استفاده از روش‌های خوشه‌بندی و همچنین پیش‌بینی یک برچسب گسسته با استفاده از الگوریتم‌های طبقه‌بندی بود. داده‌های مورد استفاده از فایل apartments-sells.csv خوانده شدند که شامل ویژگی‌هایی مانند مساحت، تعداد اتاق‌ها، سن ساختمان، وجود آسانسور، پارکینگ و انباری و همچنین قیمت هر متر مربع بودند. در ابتدای کار داده‌ها بارگذاری شدند و یک نسخه تمیز از داده‌ها برای انجام مراحل تحلیل ایجاد شد تا پردازش‌ها روی آن انجام شود.

Original Dataset shape: (71830, 11)

Column names:
['Title', 'Neighborhood', 'Area', 'Construction', 'Rooms', 'Price', 'Per_Price', 'Floor', 'Elevator', 'Parking', 'Warehouse']


First 5 rows:

Title	Neighborhood	Area	Construction	Rooms	Price	Per_Price	Floor	Elevator	Parking	Warehouse
متر تکواحدی 260 متری 24	سعادت‌آباد	260	1400	4	56000000000	215384000	5	دارد	دارد	دارد
آپارتمان 59متر سازمان آب	حکیمیه	59	1399	1	4425000000	75000000	از 5	دارد	دارد	دارد
متر 3 خواب اول فلکه اول تهرانپارس 2 پارکینگ فول	تهرانپارس غربی	147	1397	3	13000000000	88435000	از 3	دارد	دارد	دارد
آپارتمان فروشی قیطریه 80متری 2 دو خوابه اطراف پارک	قیطریه	80	1384	2	8500000000	106250000	از 1	دارد	دارد	دارد
فروش آپارتمان 52 متر بریانک (فکرش را هم نمیکند)	بریانک	52	1385	1	2280000000	43846000	از 3	ندارد	ندارد	دارد

پس از بارگذاری داده‌ها مرحله پیش‌پردازش انجام شد. در این مرحله ستون‌های عددی مورد نیاز انتخاب شدند و مقادیر آن‌ها برای استفاده در الگوریتم‌های یادگیری ماشین نرمال‌سازی شدند. دلیل انجام مقیاس‌بندی این است که بسیاری از الگوریتم‌های خوشه‌بندی مانند K-Means و DBSCAN به فاصله بین نقاط داده وابسته هستند و اگر مقیاس ویژگی‌ها متفاوت باشد نتایج الگوریتم می‌تواند دچار خطا شود. برای این کار از روش استانداردسازی استفاده شد تا تمام ویژگی‌ها میانگین صفر و واریانس یک داشته باشند.


	Area	Construction	Rooms	Price_Billion	Per_Price_Million	Building_Age	Elevator
0	260	1400.0	4.0	56.000	215.384	4.0	1
1	59	1399.0	1.0	4.425	75.000	5.0	1
2	147	1397.0	3.0	13.000	88.435	7.0	1
3	80	1384.0	2.0	8.500	106.250	20.0	1
4	52	1385.0	1.0	2.280	43.846	19.0	0
5	52	1402.0	1.0	7.280	140.000	2.0	1
6	36	1392.0	1.0	3.250	90.277	12.0	0
7	89	1397.0	2.0	9.000	101.123	7.0	1
8	50	1388.0	1.0	4.600	92.000	16.0	1
9	140	1385.0	3.0	13.000	92.857	19.0	1

در ادامه برای بررسی قابلیت خوشه‌بندی داده‌ها و همچنین تخمین تعداد مناسب خوشه‌ها از روش Elbow استفاده شد. در این روش الگوریتم K-Means برای مقادیر مختلف K اجرا می‌شود و مجموع خطای درون خوشه‌ای محاسبه می‌شود. با رسم نمودار خط نسبت به تعداد خوشه‌ها نقطه‌ای که تغییر شیب نمودار کاهش پیدا می‌کند به عنوان مقدار مناسب برای K در نظر گرفته می‌شود. این روش کمک می‌کند تا یک تخمین اولیه از ساختار داده‌ها به دست آوریم.




برای نمایش بصری خوشه‌ها از روش کاهش بعد PCA استفاده شد تا داده‌های چندبعدی به دو بعد تبدیل شوند و بتوان ساختار آن‌ها را روی نمودار مشاهده کرد. با استفاده از این روش امکان مشاهده توزیع نقاط داده و نحوه شکل‌گیری خوشه‌ها فراهم شد.


در مرحله بعد الگوریتم K-Means به عنوان یکی از رایج‌ترین روش‌های خوشه‌بندی اجرا شد. این الگوریتم با انتخاب مراکز اولیه خوشه‌ها شروع می‌کند و سپس به صورت تکراری نقاط داده را به نزدیک‌ترین مرکز خوشه اختصاص می‌دهد و مراکز جدید را محاسبه می‌کند تا زمانی که الگوریتم به همگرایی برسد. نتیجه اجرای این الگوریتم مجموعه‌ای از خوشه‌ها بود که هر کدام گروهی از آپارتمان‌ها با ویژگی‌های مشابه را نشان می‌دادند.




پس از آن الگوریتم K-Medoids اجرا شد. تفاوت این الگوریتم با K-Means در این است که مرکز هر خوشه یکی از نقاط واقعی داده است و نه میانگین آن‌ها. این ویژگی باعث می‌شود که الگوریتم نسبت به داده‌های پرت مقاوم‌تر باشد. با اجرای این الگوریتم نیز ساختار خوشه‌ها بررسی شد و نتایج آن با K-Means مقایسه شد.




در ادامه الگوریتم K-Medians مورد استفاده قرار گرفت که به جای میانگین از میانه برای تعیین مرکز خوشه استفاده می‌کند. این روش در شرایطی که داده‌ها دارای نویز یا مقادیر پرت هستند می‌تواند عملکرد بهتری داشته باشد. اجرای این الگوریتم نیز نشان داد که چگونه انتخاب معیار فاصله و مرکز خوشه می‌تواند ساختار خوشه‌ها را تغییر دهد.




یکی دیگر از روش‌هایی که در این پروژه بررسی شد Fuzzy C-Means بود. در این الگوریتم هر نقطه داده می‌تواند با درجات مختلفی به چند خوشه تعلق داشته باشد. به عبارت دیگر به جای اینکه هر داده فقط به یک خوشه اختصاص داده شود، احتمال تعلق آن به چند خوشه مختلف محاسبه می‌شود. این ویژگی در داده‌هایی که مرز مشخصی بین خوشه‌ها ندارند بسیار مفید است.




برای بررسی توانایی الگوریتم‌ها در شناسایی ساختارهای غیرخطی از Kernel K-Means استفاده شد. این روش با استفاده از تبدیل هسته‌ای داده‌ها را به فضای با بعد بالاتر نگاشت می‌کند تا الگوهایی که در فضای اولیه قابل تشخیص نیستند آشکار شوند. نتایج این روش نشان داد که در برخی موارد می‌توان ساختارهای پیچیده‌تر داده را بهتر تشخیص داد.




همچنین الگوریتم Bisecting K-Means اجرا شد. در این روش ابتدا تمام داده‌ها در یک خوشه قرار می‌گیرند و سپس خوشه‌ها به صورت تکراری به دو بخش تقسیم می‌شوند تا تعداد خوشه‌های مورد نظر به دست آید. این روش معمولا در مجموعه داده‌های بزرگ عملکرد مناسبی دارد و می‌تواند ساختار سلسله‌مراتبی داده‌ها را بهتر نشان دهد.




پس از الگوریتم‌های مبتنی بر مرکز خوشه، الگوریتم‌های مبتنی بر چگالی نیز بررسی شدند. اولین الگوریتم DBSCAN بود. این روش بر اساس چگالی نقاط داده کار می‌کند و می‌تواند خوشه‌هایی با شکل‌های دلخواه را شناسایی کند. همچنین توانایی تشخیص نقاط نویزی را نیز دارد. در اجرای این الگوریتم برخی نقاط به عنوان نویز شناسایی شدند که نشان می‌دهد این داده‌ها با هیچ خوشه‌ای سازگاری ندارند.



در ادامه الگوریتم OPTICS اجرا شد که نسخه پیشرفته‌تری از DBSCAN محسوب می‌شود و برای داده‌هایی با چگالی‌های متفاوت مناسب‌تر است. این الگوریتم ترتیب خاصی از نقاط داده تولید می‌کند که از روی آن می‌توان ساختار خوشه‌ها را استخراج کرد.



همچنین الگوریتم HDBSCAN مورد استفاده قرار گرفت که نسخه سلسله‌مراتبی DBSCAN است و به طور خودکار ساختار خوشه‌ها را در سطوح مختلف چگالی پیدا می‌کند. این الگوریتم معمولاً در داده‌های پیچیده عملکرد خوبی دارد و نیاز کمتری به تنظیم پارامترها دارد.





برای مقایسه عملکرد الگوریتم‌های مختلف از معیارهای ارزیابی خوشه‌بندی استفاده شد. معیارهایی مانند Silhouette Score، Calinski Harabasz Score و Davies Bouldin Score محاسبه شدند تا کیفیت خوشه‌ها بررسی شود. این معیارها نشان می‌دهند که نقاط داخل هر خوشه تا چه حد به یکدیگر نزدیک هستند و تا چه حد از خوشه‌های دیگر فاصله دارند. نتایج این معیارها در یک جدول مقایسه‌ای قرار داده شد تا بتوان بهترین الگوریتم را انتخاب کرد.

Comprehensive Algorithm Comparison:

algorithm	n_clusters	n_noise	silhouette	calinski_harabasz	davies_bou
ldin					
Fuzzy C-Means	4	0	0.316125	4635.201367	1.05
1237					
Standard K-Means	4	0	0.307847	5192.813628	1.08
2473					
K-Medoids	4	0	0.305259	1944.514029	1.00
4098					
Kernel K-Means	4	0	0.288236	1132.305225	1.18
4237					
K-Medians	4	0	0.288175	3980.737719	1.06
0919					
OPTICS	3	362	0.275177	4306.760238	1.33
6279					
HDBSCAN	4	151	0.261994	3732.912790	1.28
7101					
Bisecting K-Means	4	0	0.244036	3715.162733	1.02
6602					
DBSCAN	8	407	0.234627	1462.140205	0.95
2781					

پس از تحلیل نتایج مشخص شد که برخی الگوریتم‌ها نسبت به نویز مقاوم‌تر هستند و برخی دیگر ساختارهای غیرخطی را بهتر تشخیص می‌دهند. بر اساس معیارهای ارزیابی و مشاهده نمودارها یکی از الگوریتم‌ها به عنوان بهترین روش برای این داده‌ها انتخاب شد و خوشه‌های نهایی مورد تحلیل قرار گرفتند. در این تحلیل ویژگی‌های هر خوشه بررسی شد تا مشخص شود هر گروه از آپارتمان‌ها چه ویژگی‌های مشترکی دارند.



در بخش دوم پروژه مسئله طبقه‌بندی بررسی شد. در این قسمت هدف پیش‌بینی یک برچسب دودویی بود که نشان دهد آیا یک آپارتمان در دسته قیمت‌های بالاتر قرار می‌گیرد یا خیر. برای ساخت این برچسب ابتدا مقدار میانه ستون قیمت هر متر مربع محاسبه شد و سپس رکوردهایی که قیمت بالاتر از میانه داشتند به عنوان Premium و بقیه به عنوان Not Premium در نظر گرفته شدند.

```
Binary Label: is_premium
Threshold (Median Price per sqm): 91.25

Class Distribution:
is_premium
0      5002
1      4998
Name: count, dtype: int64
```

پس از تعریف متغیر هدف، داده‌ها به دو مجموعه آموزش و آزمون تقسیم شدند تا بتوان عملکرد مدل‌ها را به صورت منصفانه ارزیابی کرد. در این مرحله ویژگی‌هایی مانند مساحت، تعداد اتاق‌ها، سن ساختمان، وجود آسانسور، پارکینگ و انباری به عنوان ورودی مدل‌ها انتخاب شدند.

```
Features used for Binary Classification: ['Area', 'Rooms', 'Building_Age', 'Eleva
tor', 'Parking', 'Warehouse']

Training set size: 8000
Test set size: 2000


Training set class distribution: [4002 3998]
Test set class distribution: [1000 1000]
```

سپس چند الگوریتم مختلف طبقه‌بندی آموزش داده شدند. اولین مدل Decision Tree بود. این الگوریتم با ایجاد مجموعه‌ای از قوانین تصمیم‌گیری داده‌ها را به صورت سلسله‌مراتبی تقسیم می‌کند. مزیت این روش قابل تفسیر بودن آن است زیرا می‌توان دقیقاً مشاهده کرد که مدل بر اساس چه ویژگی‌هایی تصمیم می‌گیرد.


مدل بعدی Random Forest بود که در واقع مجموعه‌ای از چندین درخت تصمیم است. این مدل با ترکیب نتایج چند درخت مختلف دقت پیش‌بینی را افزایش می‌دهد و معمولاً نسبت به بیش‌برازش مقاوم‌تر است.

مدل دیگر Gaussian Naive Bayes بود که بر اساس قضیه بیز و با فرض استقلال ویژگی‌ها عمل می‌کند. این مدل ساده است اما در بسیاری از مسائل طبقه‌بندی عملکرد قابل قبولی دارد.

همچنین از Linear Regression نیز برای پیش‌بینی مقدار پیوسته استفاده شد و سپس خروجی آن با استفاده از آستانه 0.5 به کلاس‌های دودویی تبدیل شد. به این صورت اگر مقدار پیش‌بینی شده بزرگ‌تر یا مساوی 0.5 بود نمونه در کلاس Premium قرار می‌گرفت و در غیر این صورت در کلاس Not Premium قرار داده می‌شد.




برای ارزیابی مدل‌های طبقه‌بندی از معیارهایی مانند Accuracy، Precision، Recall و F1 Score استفاده شد. این معیارها نشان می‌دهند که مدل تا چه حد در پیش‌بینی درست کلاس‌ها موفق بوده است. نتایج این معیارها برای تمام مدل‌ها محاسبه و با یکدیگر مقایسه شدند.



به علاوه بر این برای بررسی دقیق تر عملکرد مدل ها از ماتریس درهم ریختگی استفاده شد. این ماتریس نشان می دهد که چه تعداد از نمونه ها به درستی یا به اشتباه در هر کلاس قرار گرفته اند و به درک بهتر عملکرد مدل کمک می کند.

در پایان با مقایسه نتایج مشخص شد که برخی مدل‌ها دقت بالاتری دارند و برخی دیگر قابلیت تفسیر بهتری ارائه می‌دهند. به طور کلی مدل‌هایی مانند Random Forest و Decision Tree توانستند عملکرد مناسبی در این مجموعه داده ارائه دهند و نشان دهند که ویژگی‌هایی مانند مساحت، تعداد اتاق‌ها و امکانات ساختمان نقش مهمی در تعیین سطح قیمت آپارتمان دارند.



در مجموع این پروژه نشان داد که استفاده ترکیبی از روش‌های خوشه‌بندی و طبقه‌بندی می‌تواند دید بهتری نسبت به ساختار داده‌ها ایجاد کند. خوشه‌بندی کمک کرد تا گروه‌های طبیعی در داده‌ها شناسایی شوند و طبقه‌بندی نیز امکان پیش‌بینی وضعیت قیمت آپارتمان‌ها را فراهم کرد. این نوع تحلیل می‌تواند در کاربردهای واقعی مانند تحلیل بازار مسکن و تصمیم‌گیری در خرید یا فروش ملک مفید باشد.